

Personal Finance Coach — Звіт

Архітектура

- Framework: LangGraph
- Crew: Synthesizer (router + final), Analyst, Advisor
- Baseline: single-agent tool-use loop
- Multi-turn: MemorySaver + окремий chat history на архітектуру в Streamlit
- Модель: google/gemini-2.0-flash-001

Метрики

Останній зафіксований прогін: golden set, 16 кейсів x 2 архітектури = 32 запусків.

Метрика	Crew	Baseline	Winner
latency_p50_ms	4398.5	1550.5	Baseline
latency_p95_ms	6597.5	3985.75	Baseline
cost_per_task_usd	0.00026644	0.00012123	Baseline
tokens_per_task	2121.19	1024.94	Baseline
success_rate	0.6875	0.4375	Crew
route_accuracy	0.875	0.875	Tie
tool_selection_accuracy	0.5365	0.3750	Crew
groundedness	0.7888	0.9583	Baseline
failed_tasks	0	0	Tie

Multi-agent specific

Метрика	Значення
inter_agent_overhead_pct	60.6419
completed_tasks	16
failed_tasks	0

Cost breakdown by agent

Agent	Avg cost per task (USD)
synthesizer_route	0.00003441
analyst	0.00008427

Agent	Avg cost per task (USD)
synthesizer_final	0.00011774
advisor	0.00013378

Baseline cost breakdown

Agent	Avg cost per task (USD)
baseline	0.00012123

Де crew виграє

- Краще проходить golden set: `success_rate` = 68.75% проти 43.75% у baseline.
- Краще підбирає інструменти: `tool_selection_accuracy` = 53.65% проти 37.50%.
- Дає кращу якість для сценаріїв з routing, multi-step, fraud та follow-up контекстом.

Де baseline виграє

- Швидший: p50 1550.5 ms проти 4398.5 ms у crew.
- Дешевший: \$0.00012123 на задачу проти \$0.00026644.
- Більш grounded: 0.9583 проти 0.7888.
- Простіша траєкторія для коротких factual/statistics запитів.

Рекомендації для production

1. Лишити crew для multi_step, savings, fraud і follow-up сценаріїв, де routing дає вигравш по якості.
2. Для коротких stats запитів використовувати adaptive routing на дешевший baseline path.
3. Зменшити overhead crew: запав inter_agent_overhead_pct = 60.64%, тобто orchestration занадто дорога.
4. Підсилити groundedness crew через суворіший control над tool outputs і формулюванням фінальної відповіді.
5. Продовжити regression tracking через LangSmith Dataset + Experiments.

LangSmith setup

1. Створи акаунт на smith.langchain.com.
2. Додай LANGCHAIN_API_KEY у .env.
3. Створи Dataset з eval/golden_set.py.
4. Запусти python -m eval.evaluators або Eval tab у Streamlit.

Обмеження та труднощі

- Оцінка groundedness реалізована евристично через звірку чисел у відповіді з числовими значеннями з tool outputs.
- `inter_agent_overhead_pct` вимірюється як частка токенів Synthesizer-викликів від загальних токенів crew.
- Для стабільності checkpointer токен-метрики зберігаються поза checkpointed state.
- Навіть після покращень golden set показує, що crew ще не достатньо стабільний для всіх кейсів: `success_rate = 68.75%`, тож система придатна для демо/навчального використання, але не як production-ready фінансовий copilot без подальшого тюнінгу.